

Лабораторная работа №3

Многослойные сети. Алгоритм обратного распространения ошибки

Вариант 23

Целью работы является исследование свойств многослойной нейронной сети прямого распространения и алгоритмов ее обучения, применение сети в задачах классификации и аппроксимации функции.

```
In [1]: import os
os.environ['TF_CPP_MIN_LOG_LEVEL'] = '1'


import matplotlib.pyplot as plt
import numpy as np
import tensorflow as tf
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
from tensorflow import keras
from tensorflow.keras import layers
```

Сгенерирую псевдослучайные данные для обучения и тестирования.

```
In [2]: def gen_random_ellipse_data(a, b, alpha, x_0, y_0, n):
    rand_nums = 2*np.pi*np.random.rand(n)
    x = x_0 + a * np.cos(rand_nums)
    y = y_0 + b * np.sin(rand_nums)
    xr = x * np.cos(alpha) - y * np.sin(alpha)
    yr = x * np.sin(alpha) + y * np.cos(alpha)
    return np.array([xr, yr])
```

```
In [3]: fig, ax = plt.subplots(1, 1)
data1_size = 60
data2_size = 100
data3_size = 120
data1 = gen_random_ellipse_data(0.4, 0.5, 0, 0.05, 0, data1_size)
data2 = gen_random_ellipse_data(0.6, 0.6, 0, 0.00, 0, data2_size)
data3 = gen_random_ellipse_data(0.8, 1, 0, 0.05, 0, data3_size)
ax.scatter(data1[0], data1[1])
ax.scatter(data2[0], data2[1])
ax.scatter(data3[0], data3[1])

plt.show()
```



Перегруппирую и разобью данные на тестовую и обучающую выборку.

```
In [4]: data = np.concatenate([data1, data2, data3], axis=1)
data = data.transpose()
labels1 = np.array([[1, 0, 0] for i in range(data1_size)])
labels2 = np.array([[0, 1, 0] for i in range(data2_size)])
labels3 = np.array([[0, 0, 1] for i in range(data3_size)])
labels = np.concatenate([labels1, labels2, labels3], axis=0)

X_train, X_test, y_train, y_test = train_test_split(data, labels, test_size=0.
# X_test, X_validation, y_test, y_validation = train_test_split(X_test, y_test
```

Создам нейросетевую модель. В ней будет два скрытых слоя по 20 нейронов, функцию активации везде гиперболический тангенс.

```
In [5]: model = keras.models.Sequential()
model.add(keras.layers.Dense(20, input_dim=2, activation='tanh',
                             kernel_initializer=keras.initializers.RandomN
                             bias_initializer=keras.initializers.Zeros()))
model.add(keras.layers.Dense(20, input_dim=20, activation='tanh',
                             kernel_initializer=keras.initializers.RandomN
                             bias_initializer=keras.initializers.Zeros()))
model.add(keras.layers.Dense(20, input_dim=20, activation='tanh',
                             kernel_initializer=keras.initializers.RandomN
                             bias_initializer=keras.initializers.Zeros()))
model.add(keras.layers.Dense(3, input_dim=20, activation='tanh',
                             kernel_initializer=keras.initializers.RandomN
                             bias_initializer=keras.initializers.Zeros()))

model.compile(loss='mse', optimizer='sgd', metrics=['mae'])
```

Обучу модель.

```
In [6]: epochs = 200
hist = model.fit(X_train, y_train, batch_size=5, epochs=epochs)

Epoch 1/200
40/40 [=====] - 2s 9ms/step - loss: 0.5687 - mae: 0.6172
Epoch 2/200
40/40 [=====] - 0s 7ms/step - loss: 0.3047 - mae: 0.4896
Epoch 3/200
40/40 [=====] - 0s 6ms/step - loss: 0.2484 - mae: 0.4497
Epoch 4/200
40/40 [=====] - 0s 6ms/step - loss: 0.2241 - mae: 0.4259
Epoch 5/200
40/40 [=====] - 0s 7ms/step - loss: 0.2117 - mae: 0.4088
Epoch 6/200
40/40 [=====] - 0s 6ms/step - loss: 0.2025 - mae: 0.4050
Epoch 7/200
40/40 [=====] - 0s 6ms/step - loss: 0.1962 - mae: 0.4000
```

Отрисую результат тестирования и области классификации.

```

In [7]: steps = 200
x_span = np.linspace(-1.1, 1.1, steps)
y_span = np.linspace(-1.1, 1.1, steps)
xx, yy = np.meshgrid(x_span, y_span)
grid_points = np.array([xx.ravel(), yy.ravel()])
grid_points = grid_points.transpose()

grid_predictions = model(grid_points)
grid_labels = np.argmax(grid_predictions, axis=1)

predictions = model(X_test)


fig, ax = plt.subplots(1, 2, figsize=(15, 6))

grid_labels = grid_labels.reshape(xx.shape)
ax[0].contourf(xx, yy, grid_labels, alpha=0.5)
ax[0].scatter(X_test[:, 0], X_test[:, 1], c=np.argmax(y_test, axis=1))

ax[1].plot(hist.history['loss'])

plt.show()

```



Аппроксимация

Задам функцию для аппроксимации, согласно варианту.

```

In [8]: def f(t):
        return np.sin(t**2-6*t+3)

x = np.arange(0, 5, 0.025)
y = f(x)

```

Построю и обучу модель. Модель аналогична предыдущей, за исключением активационной функции между последним скрытым и выходным слоем.

```
In [9]: model = keras.models.Sequential()
model.add(keras.layers.Dense(20, input_dim=1, activation='tanh',
                             kernel_initializer=keras.initializers.RandomN
                             bias_initializer=keras.initializers.Zeros()))
model.add(keras.layers.Dense(20, input_dim=20, activation='tanh',
                             kernel_initializer=keras.initializers.RandomN
                             bias_initializer=keras.initializers.Zeros()))
model.add(keras.layers.Dense(20, input_dim=20, activation='tanh',
                             kernel_initializer=keras.initializers.RandomN
                             bias_initializer=keras.initializers.Zeros()))
model.add(keras.layers.Dense(1, input_dim=20, activation='linear',
                             kernel_initializer=keras.initializers.RandomN
                             bias_initializer=keras.initializers.Zeros()))

model.compile(loss='mse', optimizer='sgd', metrics=['mae'])
```

```
In [10]: epochs = 200
hist = model.fit(x, y, batch_size=1, epochs=epochs)
```

```
Epoch 1/200
200/200 [=====] - 1s 5ms/step - loss: 0.3778 - mae:
0.4888
Epoch 2/200
200/200 [=====] - 1s 5ms/step - loss: 0.3014 - mae:
0.4359
Epoch 3/200
200/200 [=====] - 1s 5ms/step - loss: 0.1877 - mae:
0.3515
Epoch 4/200
200/200 [=====] - 1s 6ms/step - loss: 0.1663 - mae:
0.3185
Epoch 5/200
200/200 [=====] - 1s 5ms/step - loss: 0.1446 - mae:
0.2833
Epoch 6/200
200/200 [=====] - 1s 6ms/step - loss: 0.1272 - mae:
0.2558
Epoch 7/200
200/200 [=====] - 1s 5ms/step - loss: 0.1222 - mae:
0.2522
```

Отрисую результаты предсказаний для тоже самой функции, но по точкам с шагом меньшим в 4 раза, чем для данных для обучения.


```
In [11]: x = np.arange(0, 5, 0.025/4)

predictions = model(x)

fig, ax = plt.subplots(1, 2, figsize=(15, 6))
ax[0].plot(x, f(x))
ax[0].plot(x, predictions)

ax[1].plot(hist.history['loss'])

plt.show()
```



Выводы: в ходе выполнения лабораторной работы я изучил принципы построения и обучения многослойных нейронных сетей. Обучил многослойную нейросетевую модель для классификации по двум признакам, а также использовал аналогичную модель для аппроксимации функции. В обоих случаях модель показала неплохие результаты.

Type *Markdown* and LaTeX: α^2